

SISTEMA DE FORECASTING INTELIGENTE PARA LA MOVILIDAD URBANA

Modelo predictivo de demanda de pasajeros mediante Inteligencia Artificial

Análisis histórico, modelado descentralizado (XGBoost) y despliegue de simulador interactivo para el horizonte operativo.

Regiones de estudio: Asturias, Galicia, País Vasco y Madrid

Elaborado por: Pablo Rubio Robles

Fecha: Agosto de 2026, León

Contenido

1. Resumen ejecutivo.....	4
2. Introducción	4
3. Análisis del mercado	5
3.1. TAMAÑO Y ESTRUCTURA.....	5
3.2. TENDENCIAS Y COMPORTAMIENTO DE LA DEMANDA	5
3.3. ENTORNO Y CONDICIONES DEL SECTOR	6
4. Análisis de datos	6
4.1. GLOSARIO DE VARIABLES CLAVE.....	6
4.2. TRATAMIENTO Y LIMPIEZA DE DATOS	6
4.3. REPRESENTACIÓN VISUAL DE LOS DATOS	7
4.3.1. Evolución de la demanda.....	8
4.3.2. Evolución y tendencia de viajeros	8
4.3.3. Influencia de las variables en función de la región	9
5. Evaluación y validación de los modelos predictivos	11
5.1. ELECCIÓN DEL ALGORITMO: XGBoost	11
5.2. OPTIMIZACIÓN Y PARAMETRIZACIÓN POR REGIÓN	11
5.3. INTERPRETACIÓN DE RESULTADO Y MÉTRICAS DEL ERROR.....	12
6. Implementación operativa	13
6.1. FUNCIONAMIENTO DEL SIMULADOR.....	13
6.2. USO PARA EL NEGOCIO	14
7. Conclusiones del proyecto	14

1. Resumen ejecutivo

El presente informe detalla las conclusiones del proyecto de predicción de demanda de viajeros para las rutas operativas de buses urbanos en Asturias, Galicia, País Vasco y Madrid. Mediante el diseño e implementación de un sistema de análisis predictivo basado en algoritmos de Inteligencia Artificial, hemos logrado anticipar el volumen mensual de pasajeros con una precisión media mayor del 96%.

Este grado de exactitud se ha conseguido al enriquecer nuestros análisis con fuentes de datos externas y oficiales. Por un lado, se ha integrado la estadística de movilidad del Instituto Nacional de Estadística (INE) para comprender las tendencias de cada región y, por otro, los registros climatológicos de la Agencia Estatal de Meteorología (AEMET). Se ha demostrado que la inercia histórica de la movilidad urbana y la meteorología local son los factores más determinantes para prever los picos de ventas.

El sistema desarrollado ya está preparado para integrarse en la toma de decisiones operativa mensual, lo que permitirá a la compañía de buses urbanos, optimizar la asignación diaria de autobuses, reducir significativamente los costes derivados de mantener flota inactiva y garantizar la disponibilidad de plazas en momentos clave de alta demanda, gestionando márgenes de desviación de apenas un centenar (x1000) de pasajeros mensuales en las rutas regionales.

2. Introducción

Los datos que utilizaremos en este informe abarcan el análisis del histórico de movilidad urbana desde el año 2012 al año 2026. Para el estudio de la precisión del modelo de predicción utilizaremos los datos hasta el año 2024 y con ello calcularemos la demanda de los dos últimos años.

Para lograr de calidad y de precisión en nuestras conclusiones, se ha abandonado el cálculo manual tradicional basado en promedios simples. En su lugar, hemos adoptado una estrategia de Forecasting fundamentada en algoritmos de Inteligencia Artificial (Machine Learning), capaces de encontrar patrones complejos cruzando múltiples variables. Para alimentar este modelo y dotarlo de contexto real, el sistema se ha construido sobre dos pilares de datos públicos y oficiales:

Como indicador base del volumen de pasajeros, el modelo utiliza la Estadística de Transporte de Personas del Instituto Nacional de Estadística (INE). Dicho con otras palabras, el algoritmo se alimenta de la serie histórica de viajeros del transporte urbano por autobús agregado por Comunidad Autónoma (medido en miles de viajeros).

Para afinar las fluctuaciones a corto plazo, el modelo cruza la demanda con los registros históricos y previsiones de la Agencia Estatal de Meteorología (AEMET). Esto permite al algoritmo cuantificar matemáticamente cómo influye el clima (días de precipitación, días de calor extremo y días totalmente despejados) en la decisión de viaje del usuario.

Finalmente, estas fuentes se complementan con variables de calendario (días libres totales, fines de semana, festivos y el efecto de la Semana Santa). La convergencia de los datos del INE, la meteorología de la AEMET y nuestro calendario operativo ha dado lugar a un ecosistema de datos que permite predecir los valles y crestas de nuestra demanda con una precisión sin precedentes.

El estudio y el tratado de los datos obtenidos de las fuentes dichas darán pie al resto de los apartados del informe. En primer lugar, el Análisis del mercado contextualiza las dinámicas operativas y el marco competitivo del transporte urbano en las cuatro regiones de estudio. A continuación, en el Análisis de datos, se definen y limpian las variables del sistema y se exploran gráficamente los patrones de estacionalidad, el "efecto escala" de Madrid y la influencia de la meteorología sobre la demanda. Posteriormente, el apartado de Evaluación y validación de los modelos predictivos detalla la arquitectura de Inteligencia Artificial (XGBoost), la optimización de hiperparámetros y las métricas de error (MAPE y MAE) obtenidas para el periodo 2025-2026. Finalmente, el informe concluye con un Análisis de riesgos y las Conclusiones estratégicas recomendadas para la implantación operativa del sistema.

3.Análisis del mercado

El mercado analizado corresponde exclusivamente al sector del transporte urbano por autobús en Asturias, Galicia, País Vasco y Madrid. Este servicio es una infraestructura que garantiza la movilidad diaria dentro de las ciudades y áreas metropolitanas.

3.1.TAMAÑO Y ESTRUCTURA

Madrid es un macro-mercado urbano. Registra un volumen masivo impulsado por su altísima densidad de población, las grandes distancias metropolitanas y la masiva cantidad de desplazamientos diarios obligados.

Asturias, Galicia y País Vasco representan mercados de menor escala absoluta, pero con una demanda local importante. En estas ciudades, la orografía, la dispersión poblacional y la necesidad de conectar barrios con el centro urbano mantienen al autobús como el eje de la movilidad pública.

3.2.TENDENCIAS Y COMPORTAMIENTO DE LA DEMANDA

La demanda del autobús urbano está dictada por los desplazamientos obligados (trabajo y estudios). Por ello, experimenta caídas drásticas y predecibles durante los fines de semana, días festivos y periodos vacacionales.

Las condiciones climáticas locales alteran de forma inmediata el uso del autobús. Los días de lluvia tienden a captar a usuarios que habitualmente caminan, mientras que el buen tiempo incrementa los viajes discrecionales ligados al ocio y las compras.

3.3. ENTORNO Y CONDICIONES DEL SECTOR

El autobús urbano compite principalmente contra el uso del vehículo privado, otras redes ferroviarias locales (Metro en Madrid y Bilbao, o servicios de cercanías) y, cada vez más, frente a la micromovilidad (bicicletas y patinetes eléctricos).

La implantación obligatoria de Zonas de Bajas Emisiones (ZEB) en los municipios españoles restringe el acceso del coche privado a los centros urbanos. Esto actúa como el principal motor de crecimiento y fidelización para el mercado del autobús urbano a corto y medio plazo.

4. Análisis de datos

En este apartado buscaremos entender los datos recogidos para este proyecto. En primer lugar definiremos las variables más importantes y continuaremos haciendo un pequeño estudio sobre ellas y sobre sus relaciones.

4.1. GLOSARIO DE VARIABLES CLAVE

Para comprender correctamente el análisis y los modelos predictivos, a continuación se definen las variables que componen nuestro ecosistema de datos:

VARIABLE	DESCRIPCIÓN	FUENTE DE DATOS
VIAJEROS	Volumen total de pasajeros mensuales.	INE
VIAJEROS_lag1	Pasajeros del mes inmediatamente anterior.	Elaboración propia
VIAJEROS_lag12	Pasajeros del mismo mes del año pasado.	Elaboración propia
np_010	Número de días al mes con precipitaciones ($>0,1$ mm).	AEMET
nt_30	Número de días al mes con temperaturas máximas superiores a 30°C .	AEMET
n_des	Número de días al mes sin nubosidad significativa.	AEMET
dias_libres_totales	Volumen de días no laborables.	Calendario Laboral
semana_santa	Variable que marca en qué mes cae la Semana Santa ese año.	Calendario Laboral

Tabla 1: Variables

4.2. TRATAMIENTO Y LIMPIEZA DE DATOS

Para que el algoritmo de Machine Learning pueda interpretar correctamente el ecosistema de variables y extraer patrones válidos, la información en bruto fue sometida a un proceso de transformación matemática, limpieza y estructuración. Las técnicas aplicadas en esta fase fueron las siguientes:

Las series temporales sufrieron una ruptura estructural debido a las restricciones de movilidad causada por la pandemia del COVID-19. Por ello, se programó un filtro para

excluir por completo de la base de entrenamiento el intervalo comprendido entre marzo de 2020 y junio de 2021. Mantener esta sima antinatural habría contaminado el algoritmo, forzándole a aprender un patrón de colapso que no se corresponde con las dinámicas habituales de mercado.

Para que el modelo aprenda a usar la inercia histórica, se crearon variables de memoria (el mes anterior o *Lag1*, y el año anterior o *Lag12*). Esto provoca que los primeros 12 meses de nuestro registro histórico queden vacíos, ya que no tienen un año previo con el que compararse. Estas filas iniciales fueron eliminadas de la base de datos para garantizar que el algoritmo solo reciba registros con información completa.

Los algoritmos matemáticos no pueden leer texto (como las palabras "Madrid" o "Asturias"). Para resolverlo, se aplicó una técnica de codificación denominada One-Hot Encoding. Esta técnica transforma la columna de texto de las comunidades en múltiples columnas binarias, asignando un **1** si el dato pertenece a esa región y un **0** si no. Esta estructuración fue la pieza clave que nos permitió, posteriormente, trocear la base de datos de forma limpia y entrenar los cuatro modelos descentralizados.

Como último paso, cambiamos el enfoque del modelo para que piense en términos de crecimiento y no de cifras totales. Para ello, calculamos cuánto varía la demanda respecto al mismo mes del año anterior y a qué velocidad está creciendo a corto plazo. Este ajuste es vital ya que los algoritmos suelen tener un "techo" que les impide predecir un volumen de viajeros superior al que ya conocen de años anteriores. Al pedirle a la Inteligencia Artificial que prediga el ritmo de crecimiento en lugar del número exacto, liberamos al sistema para que sea capaz de pronosticar nuevos récords históricos de pasajeros.

4.3.REPRESENTACIÓN VISUAL DE LOS DATOS

Una vez finalizado el proceso de estructuración y limpieza de la base de datos, el paso previo al entrenamiento de la Inteligencia Artificial es el análisis exploratorio visual. La representación gráfica de las series temporales nos permite traducir los datos en información de negocio. Los siguientes paneles no solo ilustran el comportamiento histórico, la tendencia subyacente y los ciclos estacionales de la demanda, sino que exponen las profundas diferencias operativas entre los distintos territorios. Esta radiografía visual servirá como justificación para las decisiones estratégicas clave que darán forma a nuestro sistema predictivo, como la exclusión del periodo de pandemia o la necesidad ineludible de separar el macro-mercado de Madrid del resto de regiones.

4.3.1. Evolución de la demanda

El gráfico muestra la serie temporal completa del volumen de viajeros desde el año 2012 hasta 2026. Al observar los datos en bruto, el panel revela dos realidades operativas fundamentales que han condicionado el diseño de nuestro sistema predictivo:




Tabla 2: Evolución de la demanda

En primer lugar, se aprecia de forma unánime un colapso drástico en la movilidad en la primavera de 2020. Esta caída rompe por completo la tendencia natural del mercado, justificando nuestra decisión de aislar y eliminar el periodo de pandemia (marzo 2020 - junio 2021) de la base de entrenamiento para que el algoritmo no aprenda un comportamiento anómalo que ya no representa la realidad actual.

Asimismo, se observa que la curva de Madrid (línea verde) domina por completo el gráfico, oscilando con picos masivos de entre 20.000 y 60.000 pasajeros mensuales. Por el contrario, las regiones del norte (Asturias, Galicia y País Vasco) quedan comprimidas en la parte inferior del eje, con volúmenes que rara vez superan los 10.000 viajeros.

Si introduyéramos todos estos datos juntos en un único modelo predictivo global, el algoritmo sufriría de lo que matemáticamente se conoce como sesgo de escala. El sistema centraría todos sus esfuerzos en minimizar los errores en Madrid (donde fallar un 5% supone un desvío de miles de pasajeros) e ignoraría por completo las dinámicas climáticas y de calendario del Norte, al considerarlas matemáticamente "insignificantes" en el volumen total.

Esta evidencia visual es la justificación principal que nos llevó a descentralizar el sistema y entrenar modelos independientes por región, evitando así que el macro-mercado madrileño "canibalizara" la precisión de las regiones del norte.

4.3.2. Evolución y tendencia de viajeros

Para que nuestro sistema predictivo alcance su máxima precisión, es fundamental separar el "ruido" de la verdadera realidad estructural del negocio. A simple vista, la curva total de viajeros puede parecer caótica debido a las continuas variaciones de cada mes. Por ello, hemos aplicado una técnica de descomposición temporal que disecciona

la demanda en sus dos componentes principales: la dirección real que lleva la demanda a largo plazo y el comportamiento cíclico que se repite año tras año.




Tabla 3: Tendencia de viajeros

El gráfico superior aísla la tendencia pura del mercado (línea azul oscuro). Al limpiar el ruido de los picos mensuales, se evidencia un crecimiento base constante y sostenido desde la recuperación post-pandemia. Además, el área sombreada en rojo ilustra la ruptura estructural que supuso el COVID-19, justificando la exclusión de este periodo anómalo para no contaminar el aprendizaje del algoritmo predictivo.

Por su parte, el panel inferior muestra el patrón cíclico estacional. Esta curva naranja representa el impacto repetitivo que tienen los meses del año sobre la demanda (picos en temporadas de alta movilidad y valles en épocas de menor actividad urbana). Esta alta previsibilidad cíclica es precisamente el patrón que nuestra Inteligencia Artificial ha logrado interiorizar para anticipar las ventas futuras.

4.3.3. Influencia de las variables en función de la región

Para entender qué factores impulsan realmente el uso de autobuses urbanos, se han generado dos mapas de calor o matrices de correlación que miden la relación entre el volumen de pasajeros y variables externas como el clima o el calendario. El color rojo oscuro (valores cercanos a 1) indica una relación directa muy fuerte, mientras que los tonos azules (valores negativos) indican que esa variable reduce la demanda.




Tabla 4: Correlación de variables

Al separar el análisis entre Madrid y el Norte peninsular (Asturias, Galicia y País Vasco), descubrimos comportamientos de mercado radicalmente distintos que justifican nuestra estrategia de diseñar algoritmos independientes para cada región:

Si observamos la primera columna del gráfico del Norte, el volumen de viajeros está dictado casi en su totalidad por la inercia del mes anterior y del mismo mes del año pasado. Esto nos indica que el mercado asturiano, vasco y gallego es muy constante, es decir, es una demanda recurrente que se puede predecir con gran exactitud basándonos en el histórico. En Madrid, la inercia también es importante, pero notablemente menor (0.68 y 0.61), lo que indica un mercado más volátil donde los factores externos alteran más la demanda.

Al cruzar los viajeros con la meteorología de AEMET, los datos rompen nuestras intuiciones iniciales:

- **En Madrid:** El clima sí influye en la demanda mensual. Los días de lluvia (np_010 con 0.22) incrementan el uso del autobús (probablemente usuarios que evitan caminar o usar micromovilidad). Por el contrario, los días de calor extremo (nt_30 con -0.29) y los días despejados (n_des con -0.22) reducen el uso del transporte público.
- **En el Norte:** El clima no altera el patrón de movilidad urbana agregado mensualmente. La correlación de la lluvia o los días despejados es prácticamente inexistente (en torno a 0.05). En estas regiones, el usuario coge el autobús por necesidad, llueva o haga sol.

En ambas matrices, las variables de días libres y Semana Santa muestran colores grises (correlaciones cercanas a 0). Esto se debe a que, al analizar la demanda a nivel de *mes completo*, el impacto de unos pocos días festivos se diluye en el total mensual, perdiendo fuerza predictiva directa frente a la macro-tendencia.

Conclusión Estratégica: Esta evidencia visual es la prueba definitiva de que un único modelo global fracasaría. Al separar el modelo predictivo por regiones, permitimos que el algoritmo de Madrid le dé importancia a la lluvia para ajustar su predicción, mientras que los modelos del Norte ignorarán la meteorología y se apoyarán en su fortísima inercia histórica.

5.Evaluación y validación de los modelos predictivos

En este apartado se detallan la arquitectura técnica y los resultados obtenidos tras evaluar el desempeño del sistema predictivo sobre el conjunto de test (período "fuera de muestra" correspondientes a 2025-2026).

5.1.ELECCIÓN DEL ALGORITMO: XGBoost

Para desarrollar el pronóstico, se ha descartado el uso de modelos estadísticos tradicionales (como ARIMA) en favor del algoritmo XGBoost. La elección de este modelo de *Machine Learning* basado en árboles de decisión se fundamenta en tres ventajas técnicas para nuestro caso de uso:

- **Gestión de variables:** XGBoost es altamente eficiente cruzando series temporales con factores externos (meteorología y calendario).
- **Relaciones no lineales:** Es capaz de entender que la lluvia afecta a la demanda en Madrid, pero no en Asturias, sin necesidad de programar estas reglas manualmente.
- **Robustez frente a valores atípicos:** Al estar basado en la construcción secuencial de árboles de decisión, el modelo es altamente resistente al "ruido" estadístico habitual en la venta de billetes diaria.

5.2.OPTIMIZACIÓN Y PARAMETRIZACIÓN POR REGIÓN

Para capturar la heterogeneidad de la demanda, se descartó un modelo único y se optó por un enfoque descentralizado. Mediante una técnica de validación cruzada (*Grid Search*), el sistema evaluó miles de combinaciones matemáticas para asignar a cada Comunidad Autónoma su configuración óptima. Todos los modelos comparten una tasa de aprendizaje conservadora (`learning_rate = 0.04`) y un volumen de 150 árboles secuenciales (`n_estimators = 150`), pero difieren estratégicamente en su complejidad:

En Galicia usamos una profundidad de árbol igual a 3 (`max_depth=3`). Esto se debe a que Galicia presenta una estacionalidad sumamente marcada (fuerte concentración en los meses estivales). El algoritmo determinó que necesitaba un nivel de profundidad mayor (nivel 3) para poder ramificar y capturar interacciones de variables más complejas sin incurrir en sobreajuste (*overfitting*).

En Asturias, País Vasco y Madrid la profundidad de árbol es igual a 2 (`max_depth = 2`). Esto se debe a que para estas tres regiones, el algoritmo seleccionó la arquitectura más simple. Una profundidad baja actúa como un regularizador natural, es decir, evita que

el modelo "memorice" el ruido aleatorio del clima o de fluctuaciones puntuales, obligándole a priorizar la tendencia estructural y cíclica de fondo.

A continuación, se presenta el panel visual que contrasta la demanda real frente a las predicciones del modelo:




Tabla 5: Precisión del modelo

5.3.INTERPRETACIÓN DE RESULTADO Y MÉTRICAS DEL ERROR

La configuración a medida de estos hiperparámetros ha permitido que las proyecciones repliquen con gran fidelidad los picos y valles de 2025 y 2026. A continuación, se extrae el cuadro de mando generado por el sistema, el cual consolida los márgenes de error definitivos para cada territorio:

MÉTRICAS DEL MODELO FINAL COMBINADO (Test 2025-2026)			
Asturias	-> MAPE: 3.66%	MAE: 139 viajeros	(Depth=2)
Galicia	-> MAPE: 2.12%	MAE: 124 viajeros	(Depth=3)
País Vasco	-> MAPE: 5.52%	MAE: 502 viajeros	(Depth=2)
Madrid	-> MAPE: 4.39%	MAE: 2214 viajeros	(Depth=2)

Tabla 6: Errores

Para medir esta exactitud matemática y comprender el impacto real de estos resultados, utilizamos los dos indicadores clave expuestos en la tabla superior:

- **MAPE (Error Porcentual Absoluto Medio):** Mide el porcentaje de desviación de nuestras predicciones. Las cuatro regiones presentan un desempeño sobresaliente al mantenerse **por debajo del 6% de error** (destacando Galicia con

un extraordinario 2,12% y Asturias con un 3,49%). En *forecasting* de demanda, cualquier valor inferior al 10% se considera un estándar de precisión excelente para pasar a producción.

- **MAE (Error Absoluto Medio):** Indica la desviación en número real de pasajeros. Mientras que en Asturias el margen de error típico es de apenas 130 viajeros mensuales (recordemos que estamos hablando x1000 viajeros), en Madrid asciende a unos 2.100 viajeros. Esta diferencia absoluta no implica que el modelo de la capital sea deficiente, sino que absorbe el impacto proporcional de gestionar un macro-mercado que moviliza picos de hasta 60.000 usuarios mensuales.

En conclusión, la estrategia de segmentar la IA y parametrizar los modelos según la orografía de los datos de cada territorio garantiza un pronóstico extremadamente robusto y fiable para la planificación operativa y financiera de la compañía.

6. Implementación operativa

El objetivo último de este proyecto no es únicamente comprender el pasado, sino dotar al usuario de herramientas accionables para el futuro. Para ello, los algoritmos desarrollados han sido encapsulados y desplegados en un Simulador Interactivo en la nube, accesible para un equipo directivo y de operaciones desde cualquier dispositivo.

Este panel actúa como un entorno de pruebas seguro (análisis What-If) que permite al usuario plantear escenarios hipotéticos y observar cómo reaccionaría la demanda de viajeros en tiempo real.

6.1. FUNCIONAMIENTO DEL SIMULADOR

La interfaz oculta la complejidad matemática y permite al usuario interactuar con controles sencillos. Al seleccionar un mes de referencia y alterar variables como los días de lluvia, las olas de calor o los festivos, el sistema cruza estos datos introducidos por el usuario con la base de datos de la compañía. En cuestión de milisegundos, el modelo XGBoost procesa el escenario y




Tabla 7: Simulador predictivo

recalcula la previsión absoluta de pasajeros, indicando si las condiciones generarán un crecimiento o una contracción de las ventas.

URL DEL SIMULADOR: <https://prediccion-demanda-buses-urbanos-agbqzlxvicuorbaeuqzgua.streamlit.app/>

6.2.USO PARA EL NEGOCIO

Optimización de Flota y Personal: Permite a los jefes de tráfico ajustar los cuadrantes de conductores, vacaciones y mantenimientos de autobuses en función de la previsión de valles y picos de demanda.

Previsión Financiera: Ayuda al departamento financiero a proyectar los ingresos por venta de billetes con meses de antelación, ajustando presupuestos y estimando el flujo de caja.

Pruebas de estrés operativo: Permite simular escenarios extremos (por ejemplo, un mes inusualmente lluvioso combinado con festivos) para garantizar que la empresa disponga de capacidad suficiente y evitar el colapso del servicio.

7.Conclusiones del proyecto

El desarrollo de este sistema predictivo marca un salto cualitativo en la madurez analítica de la planificación operativa de una compañía. Tras el análisis, modelado y validación de los datos históricos (2012-2024) y su proyección hacia el horizonte 2025-2026, se extraen las siguientes conclusiones fundamentales:

Superioridad de la Inteligencia Artificial: La adopción del algoritmo Machine Learning (XGBoost) ha demostrado ser inmensamente superior a los métodos de promedios tradicionales. El modelo ha logrado capturar las relaciones no lineales complejas entre el clima, el calendario y la movilidad ciudadana, alcanzando márgenes de error (MAPE) inferiores al 6% en todas las regiones, un estándar de excelencia en el forecasting de demanda.

La necesidad de segmentación territorial: El análisis visual confirmó que un modelo único nacional habría fracasado debido al "sesgo de escala" de Madrid. La decisión estratégica de crear arquitecturas descentralizadas e independientes ha permitido respetar la sensibilidad climática de la capital y la fuerte inercia histórica de la cornisa cantábrica (Asturias, Galicia y País Vasco).

Ingeniería de datos como pilar del éxito: El aislamiento del periodo anómalo de la pandemia (COVID-19) y la transformación de la variable objetivo hacia el crecimiento interanual han sido las claves técnicas que han permitido al sistema superar sus limitaciones de extrapolación, logrando predecir nuevos récords históricos de demanda sin estancarse en el pasado.

Preparación para el entorno productivo: El proyecto ha culminado con éxito su fase de laboratorio y ha sido empaquetado en una solución de software interactiva. El sistema está técnicamente listo para integrarse en la toma de decisiones diaria de la compañía, garantizando un servicio más eficiente y rentable.